PROGRAMA DE ASIGNATURA · ACTUALIZACIÓN 2027-1

PROCESAMIENTO DIGITAL DE IMÁGENES

Maestría en Ciencia de Datos e Información (MCDI) · INFOTEC · Ciclo escolar 2027-1

Dato	Valor
Clave	MCDI00010
Programa	Maestría en Ciencia de Datos e Información (MCDI)
Ciclo	3 (ciclo escolar 2027-1)
Tipo de ciclo	Semestral
Modalidad	A distancia (en línea), con sesiones síncronas por videoconferencia
Periodo	11 de enero de 2027 al 21 de mayo de 2027
Duración	[Por confirmar con Coordinación] horas docentes / [Por confirmar con Coordinación] horas independientes
Docente	Dr. Edgar González Fernández (edgar.gonzalezf@infotec.mx)

1. Presentación

¿De qué trata la asignatura?

Procesamiento digital de imágenes es una asignatura que aborda las técnicas básicas para procesar, analizar y transformar imágenes digitales. A lo largo del curso aprenderás a mejorar la calidad de una imagen, segmentar objetos, extraer características como la textura, la forma y el color, y usar estos datos en algoritmos de aprendizaje automático. El enfoque de estudio es práctico: trabajarás con imágenes reales en cuadernos Jupyter con Python y OpenCV.

¿Por qué es importante para tu formación?

Hoy día muchas aplicaciones de ciencia de datos incluyen imágenes, desde fotografías y video hasta imágenes médicas o satelitales. Obtendrás las bases para convertir imágenes en datos útiles para el análisis y fortalecerás tus habilidades en programación, estadística y modelado para resolver problemas concretos de visión artificial, evaluando cada resultado con métricas objetivas.

¿Cómo aplicarás los conocimientos en el campo laboral?

Estarás facultado para participar en proyectos en los que se requiera clasificar imágenes, detectar objetos, segmentar regiones o evaluar la calidad de imágenes, por ejemplo, en salud, industria, agro, seguridad y marketing. Estos conocimientos te permitirán desarrollar soluciones de visión por computador reproducibles y colaborar con equipos multidisciplinarios de análisis de datos e inteligencia artificial.

2. Alcance de la actualización

Esta actualización conserva la estructura vigente de la asignatura: las cinco unidades con su nombre, número y subtemas, y las cinco actividades individuales con su ponderación. Se

incorporan únicamente los cambios más relevantes para un posgrado profesionalizante en ciencia de datos: la evaluación cuantitativa de cada etapa, la validación de modelos sin fuga de datos, una introducción a la transferencia de aprendizaje y material de apoyo reproducible (cuadernos, presentaciones y datos en un repositorio público).

Aspecto	Cambio respecto al plan vigente
Unidades y subtemas	Sin cambio: 5 unidades con su nombre, número y subtemas. Se precisa el alcance de cada subtema.
Actividades y ponderación	Sin cambio: 1A–5A, individuales, 10/15/20/25/30 puntos y los mismos criterios de las listas de cotejo, con precisiones menores.
Evaluación cuantitativa	Se incorporan métricas: PSNR/SSIM en 2A, IoU/Dice contra una máscara de referencia en 3A, estandarización antes de PCA en 4A, validación cruzada, matriz de confusión y F1 en 5A.
Contenidos actualizados	CLAHE y filtrado en frecuencia (U2); watershed y panorama de U-Net/SAM (U3); LBP (U4); Pipeline, fuga de datos y panorama de transferencia de aprendizaje (U5).
Datos de práctica	Repositorio del curso con imágenes de uso libre organizadas por unidad, incluidas máscaras de referencia y parches de textura.
Sesiones síncronas	6 clases de 2 horas (jueves de 11:00 a 13:00, a partir del 14 de enero) y 11 sesiones opcionales de seguimiento y evaluación (jueves de 12:00 a 13:00).
Uso de IA y defensa oral	Declaración obligatoria del uso de IA en cada entrega y defensa oral individual con selección pseudoaleatoria, conforme a los lineamientos del curso propedéutico y al documento «Uso adecuado de la IA».
Material de sesiones	6 cuadernos Jupyter ejecutados y 6 presentaciones, una por clase; un cuaderno plantilla por actividad.
Referencias	Se conservan las referencias vigentes (formato APA corregido, sin duplicados) y se llenan los apartados «Complementa», que estaban vacíos.
Correcciones	Se corrige la numeración de la Unidad 5 (aparecía como «Unidad 4. Reconocimiento de imágenes») y se retiran las instrucciones para el experto que quedaron en las unidades 2 a 5.

3. Fin de formación de la asignatura

Aplicar los conceptos básicos teórico-prácticos relacionados con el procesamiento digital de imágenes, para extraer, estructurar y analizar información contenida en imágenes, y utilizarla en algoritmos de aprendizaje automático y tareas de visión artificial, evaluando los resultados con métricas pertinentes, bajo un enfoque analítico y reproducible.

4. Fin de formación por unidad

Unidad	Fin de aprendizaje	Evidencia

1. Introducción al procesamiento digital de imágenes	Comprender el papel del procesamiento digital de imágenes en la ciencia de datos e implementar operaciones básicas de lectura, visualización, manipulación geométrica y almacenamiento de imágenes digitales usando OpenCV en un entorno reproducible, identificando su representación como arreglos numéricos (resolución, tipo de dato y canales de color).	1A
2. Preprocesamiento	Aplicar técnicas de preprocesamiento de imágenes (transformaciones de intensidad, filtrado espacial y frecuencial, operaciones morfológicas y transformaciones geométricas) y evaluar su impacto en la calidad de la imagen mediante criterios visuales y métricas cuantitativas (MSE, PSNR y SSIM), comparando alternativas y argumentando la selección de los esquemas de preprocesamiento más adecuados, como base para etapas posteriores de segmentación y reconocimiento.	2A
3. Segmentación	Implementar y comparar distintos métodos de segmentación de imágenes (detección de bordes, umbralización y agrupamiento por intensidades/regiones) para separar objetos del fondo, analizando sus ventajas y limitaciones según el tipo de imagen y el problema de interés, comparando alternativas con métricas de coincidencia (IoU y Dice) y argumentando la pertinencia de cada método en función de las características de la imagen y del problema planteado.	3A
4. Descripción y representación de imágenes digitales	Construir y analizar descriptores de textura, forma y color para representar imágenes de manera compacta y significativa, y aplicar una técnica básica de reducción de dimensión (por ejemplo, PCA) sobre características estandarizadas para visualizar y explorar la separación entre clases o tipos de imágenes.	4A
5. Reconocimiento de imágenes	Diseñar e implementar un flujo completo de procesamiento digital de imágenes, que incluya preprocesamiento, segmentación, extracción de descriptores y aplicación de un modelo de aprendizaje automático (supervisado o no supervisado), evaluando su desempeño con validación adecuada y métricas pertinentes, y discutiendo sus alcances y limitaciones.	5A

5. Contenido temático

Unidad 1. Introducción al procesamiento digital de imágenes · Semanas 1 y 2 (11 al 24 de enero)

- **1.1. Visión natural** (formación de la imagen en el ojo humano y percepción del color).
- **1.2. Visión artificial** (del sensor a la imagen digital; aplicaciones y consideraciones éticas (privacidad y sesgo)).
- **1.3. Conceptos básicos sobre el procesamiento digital de imágenes** (muestreo y cuantización, la imagen como arreglo (dimensiones, canales, tipo de dato), espacios de color (RGB/BGR, gris, HSV), formatos y compresión, entorno reproducible).

Unidad 2. Preprocesamiento · Semanas 3 a 5 (25 de enero al 14 de febrero)

- **2.1. Mejoramiento de la imagen** (transformaciones de intensidad, histograma, ecualización y CLAHE; métricas de calidad MSE, PSNR y SSIM).
- **2.2. Procesamiento espacial y frecuencial** (convolución; filtros promedio, gaussiano, mediana y de realce; transformada de Fourier y filtros pasa-bajas/pasa-altas).
- **2.3. Operaciones morfológicas** (erosión, dilatación, apertura, cierre y top-hat sobre imágenes binarizadas).
- **2.4. Transformaciones geométricas** (rotación, escalamiento, recorte, transformaciones afines y su uso para aumento de datos).

Unidad 3. Segmentación · Semanas 6 a 8 (15 de febrero al 7 de marzo)

- **3.1. Introducción sobre segmentación de imágenes** (objetivos y tipos de segmentación; evaluación contra una referencia (IoU y Dice); panorama de U-Net y Segment Anything).
- **3.2. Segmentación por discontinuidades** (gradiente, Sobel, Canny y transformada de Hough).
- **3.3. Segmentación por similaridad** (umbralización global, Otsu y adaptativa; componentes conexas y watershed; agrupamiento k-means).

Unidad 4. Descripción y representación de imágenes digitales · Semanas 9 a 12 (8 de marzo al 4 de abril)

- **4.1. Introducción sobre descripción y representación de imágenes digitales** (del píxel al vector de características; propiedades de un buen descriptor).
- **4.2. Variables y descriptores** (descriptores de forma: área, perímetro, circularidad, excentricidad y momentos de Hu).
- **4.3. Representación de imágenes** (matriz de diseño, estandarización y visualización con PCA).
- **4.4. Texturas** (matriz de co-ocurrencia (GLCM, Haralick) y patrones binarios locales (LBP)).
- **4.5. Color** (histogramas y momentos de color en RGB y HSV).
- **4.6. Extracción de características** (vector combinado de características; HOG y embeddings de redes preentrenadas como referencia).

Unidad 5. Reconocimiento de imágenes · Semanas 13 a 19 (5 de abril al 21 de mayo)

- **5.1. Aprendizaje automático** (formulación del problema, matriz de diseño y Pipeline de scikit-learn).
- **5.2. Algoritmos supervisados aplicados a imágenes** (k-NN, SVM, árboles y Random Forest; introducción a redes convolucionales y transferencia de aprendizaje).
- **5.3. Algoritmos no-supervisados aplicados a imágenes** (k-means sobre descriptores y comparación de grupos con etiquetas).
- **5.4. Reducción de la dimensión** (PCA dentro del Pipeline y t-SNE para exploración).
- **5.5. Evaluación del desempeño de los modelos** (particiones estratificadas y por grupo, validación cruzada, matriz de confusión, precisión, exhaustividad y F1; fuga de datos).

6. Metodología de trabajo

El curso sigue el modelo de aprendizaje activo de los posgrados de INFOTEC, con estrategias de aprendizaje basado en problemas, método de casos y aprendizaje basado en proyectos:

- Aprendizaje basado en problemas: cada actividad parte de un problema de imágenes reales que se resuelve en un cuaderno Jupyter.
- Método de casos: las sesiones síncronas se apoyan en casos aplicados (inspección de materiales, conteo de objetos, documentos, rostros) para discutir decisiones de diseño.
- Aprendizaje basado en proyectos: la actividad 5A integra el flujo completo (preprocesamiento → segmentación → descriptores → modelo) con un conjunto de imágenes elegido por el estudiante.
- Cuadernos guiados: por cada unidad hay un cuaderno de sesión con ejemplos paso a paso y un cuaderno plantilla alineado con la lista de cotejo, ejecutables en Google Colab.
- Evaluación formativa con listas de cotejo publicadas desde el inicio y retroalimentación escrita en cada entrega.
- Integridad académica: el uso de IA se declara en cada entrega y la calificación puede confirmarse con una defensa oral individual (selección pseudoaleatoria).

Sesiones síncronas

Se imparten seis clases síncronas de dos horas (jueves de 11:00 a 13:00 hrs.), cada una apoyada en una presentación y un cuaderno Jupyter ejecutable en Google Colab con ejemplos paso a paso. Además, se ofrecen sesiones opcionales de seguimiento (dudas) y de evaluación (retroalimentación y defensas orales) los jueves de 12:00 a 13:00 hrs.

Unidad	Sesión	Fecha y horario
1	Clase 1. La imagen como arreglo numérico	Jueves 14 de enero, de 11:00 a 13:00
1	Seguimiento (opcional). Dudas de la actividad 1A	Jueves 21 de enero, de 12:00 a 13:00
1	Evaluación (opcional). Retroalimentación de 1A y defensas orales	Jueves 28 de enero, de 12:00 a 13:00
2	Clase 2. Preprocesar con evidencia: filtrar, medir y decidir	Jueves 4 de febrero, de 11:00 a 13:00
2	Seguimiento (opcional). Dudas de la actividad 2A	Jueves 11 de febrero, de 12:00 a 13:00
2	Evaluación (opcional). Retroalimentación de 2A y defensas orales	Jueves 25 de febrero, de 12:00 a 13:00
3	Clase 3. Separar objetos del fondo y medir qué tan bien lo hacemos	Jueves 18 de febrero, de 11:00 a 13:00
3	Seguimiento (opcional). Dudas de la actividad 3A	Jueves 4 de marzo, de 12:00 a 13:00

3	Evaluación (opcional). Retroalimentación de 3A y defensas orales	Jueves 18 de marzo, de 12:00 a 13:00
4	Clase 4. De la imagen al vector: descriptores y PCA	Jueves 11 de marzo, de 11:00 a 13:00
4	Seguimiento (opcional). Dudas de la actividad 4A	Jueves 1 de abril, de 12:00 a 13:00
4	Evaluación (opcional). Retroalimentación de 4A y defensas orales	Jueves 8 de abril, de 12:00 a 13:00
5	Clase 5. Reconocimiento: del clasificador clásico a la transferencia de aprendizaje	Jueves 15 de abril, de 11:00 a 13:00
5	Seguimiento (opcional). Avance de la actividad 5A	Jueves 29 de abril, de 12:00 a 13:00
5	Clase 6. Flujo completo de procesamiento y reconocimiento	Jueves 6 de mayo, de 11:00 a 13:00
5	Seguimiento (opcional). Dudas de la actividad 5A	Jueves 13 de mayo, de 12:00 a 13:00
5	Evaluación (opcional). Retroalimentación de 5A y defensas orales	Jueves 20 de mayo, de 12:00 a 13:00

7. Evaluación

La evaluación es formativa y sumativa. Cada actividad cuenta con una lista de cotejo publicada desde el inicio del curso; el docente retroalimenta por escrito cada entrega.

Clave	Actividad	Tipo	Fecha límite	Puntos
1A	Introducción y manipulación básica de imágenes con OpenCV	Individual	Domingo 24 de enero de 2027	10
2A	Preprocesamiento de imágenes con OpenCV	Individual	Domingo 14 de febrero de 2027	15
3A	Segmentación de imágenes con OpenCV	Individual	Domingo 7 de marzo de 2027	20
4A	Descriptores de textura, forma y color con reducción de dimensión	Individual	Domingo 4 de abril de 2027	25
5A	Flujo completo de procesamiento y reconocimiento	Individual	Domingo 16 de mayo de 2027	30
	Total			**100**

Uso de inteligencia artificial y defensa oral

Regla de oro: Entrega solo código y análisis que puedas explicar y modificar línea por línea.

Usos permitidos:

- Comprender conceptos: pedir explicaciones adicionales, ejemplos o analogías sobre un tema visto en clase.

- Depurar: identificar errores en tu propio código ya elaborado y entender por qué ocurren.
- Practicar: generar ejercicios o variantes adicionales para reforzar un tema.
- Revisar la forma: redacción, ortografía o claridad de un texto cuyo contenido e ideas son tuyos.
- Explorar: orientarte sobre posibles enfoques antes de resolver el problema por tu cuenta.

Usos no permitidos:

- Entregar como propio código, texto, figuras o resultados generados por IA sin declararlo.
- Pedir a la IA la solución completa de la actividad en lugar de usarla como apoyo puntual.
- Entregar código que no entiendas o no puedas modificar.
- Usar asistentes de IA (incluido Gemini en Colab) durante una defensa oral.

Declaración obligatoria al final de cada libreta:

- Herramienta utilizada (nombre y, si aplica, versión).
- Para qué la usaste (por ejemplo, «depuración de la sección 3» o «redacción de la conclusión»).
- Qué partes del trabajo son resultado directo de la IA y cuáles son de tu autoría.
- Si no usaste IA, indícalo expresamente: «No utilicé herramientas de IA en esta actividad».

Defensa oral:

- En cada actividad se selecciona de forma pseudoaleatoria a un grupo de estudiantes; cualquier entrega puede ser seleccionada.
- La defensa es una entrevista individual por videollamada (10–15 min) en las sesiones de evaluación de los jueves o en un horario acordado con el docente.
- Se comparte la pantalla completa, sin asistentes de IA ni otras pestañas, y se trabaja sobre la propia libreta entregada.
- Se plantean 4 a 5 preguntas sobre el código (cualquier línea), la lógica de la solución y la teoría; puede pedirse modificar el código y volver a ejecutarlo.

Situación	Consecuencia
Uso de IA no declarado	La entrega se revisa con mayor rigor y puede considerarse falta a la integridad académica conforme al reglamento de INFOTEC.
Respuesta inadecuada en la defensa oral	Se descuentan los puntos de los criterios de la lista de cotejo relacionados con la pregunta.
No responder ninguna pregunta de la defensa	La entrega completa puede anularse (0 puntos).
No presentarse a la defensa sin causa justificada	La calificación de la entrega no se confirma (0 puntos).

Lineamientos basados en el documento «Uso adecuado de la IA en el ámbito académico» (INFOTEC) y en las reglas de evaluación del curso propedéutico de la MCDI.

8. Requerimientos técnicos

- Computadora con navegador actualizado (Chrome, Firefox o Edge), al menos 8 GB de RAM y conexión a internet de 10 Mbps o superior.
- Cuenta de Google para usar Google Colab (entorno recomendado, sin instalación).

- Opcional, entorno local: Python 3.10 o superior con numpy, matplotlib, pandas, opencv-python, scikit-image y scikit-learn (archivo requirements.txt en el repositorio del curso). Para el ejemplo opcional de transferencia de aprendizaje de la Unidad 5: torch y torchvision.
- Cámara, micrófono y audífonos para las videoconferencias.
- Cuenta de GitHub (recomendada) para descargar el material del curso y versionar tus cuadernos.

9. Materiales de apoyo

- Repositorio del curso con sitio web (programa, calendario, actividades, recursos y datos): https://github.com/egonzalez1989/pdi-mcdi
- 6 cuadernos Jupyter de sesión síncrona (ejecutados y verificados) y 6 presentaciones (.pptx) con notas para el docente.
- 5 cuadernos plantilla para las actividades 1A a 5A, alineados con su lista de cotejo.
- 5 listas de cotejo y la agenda del curso en el formato institucional.

10. Referencias básicas

Giménez-Palomares, F., Monsoriu, J. A., y Alemany-Martínez, E. (2016). Aplicación de la convolución de matrices al filtrado de imágenes. Modelling in Science Education and Learning, 9(1), 97–108. https://doi.org/10.4995/msel.2016.4524

Hall-Beyer, M. (2017). GLCM texture: A tutorial (v. 3.0). [Documento en PDF]. University of Calgary. https://prism.ucalgary.ca/handle/1880/51900

Haralick, R. M., Shanmugam, K., & Dinstein, I. (1973). Textural features for image classification. IEEE Transactions on Systems, Man, and Cybernetics, 3(6), 610–621. https://doi.org/10.1109/TSMC.1973.4309314

Hu, M.-K. (1962). Visual pattern recognition by moment invariants. IRE Transactions on Information Theory, 8(2), 179–187. https://doi.org/10.1109/TIT.1962.1057692

Imagina Formación. (2024). Procesamiento de imágenes con OpenCV en Python. [Página web]. https://imaginaformacion.com/tutoriales/opencv-en-python

Keen, N. (2005). Color moments. [Documento en PDF]. University of Edinburgh. https://homepages.inf.ed.ac.uk/rbf/CVonline/LOCAL_COPIES/AV0405/KEEN/av_as2_nkeen.pdf

León-Batallas, A., Bermeo-Paucar, J., Paredes-Quevedo, J., y Torres-Ordoñez, H. (2020). Una revisión de las métricas aplicadas en el procesamiento de imágenes. RECIMUNDO, 4(3), 267–273. https://doi.org/10.26820/recimundo/4.(3).julio.2020.267-273

Mazet, V. (2021). Filtering. [Página web]. Basics of Image Processing. https://vincmazet.github.io/bip/filtering/filtering.html

Mazet, V. (2021). Histogram transformations. [Página web]. Basics of Image Processing. https://vincmazet.github.io/bip/digital-images/histogram.html

Najman, L. (s.f.). Segmentation – basics. [Documento en PDF]. https://www.laurentnajman.org/uploads/ImageCourse/segmentation1_ln.pdf

OpenCV. (s.f.). Arithmetic operations on images. [Página web]. https://docs.opencv.org/4.x/d0/d86/tutorial_py_image_arithmetics.html

OpenCV. (s.f.). Basic operations on images. [Página web]. https://docs.opencv.org/4.x/d3/df2/tutorial_py_basic_ops.html

OpenCV. (s.f.). Canny edge detection. [Página web]. https://docs.opencv.org/4.x/da/d22/tutorial_py_canny.html

OpenCV. (s.f.). Image file reading and writing (imgcodecs). [Página web]. https://docs.opencv.org/4.x/d4/da8/group__imgcodecs.html

OpenCV. (s.f.). Image thresholding. [Página web]. https://docs.opencv.org/4.x/d7/d4d/tutorial_py_thresholding.html

OpenCV. (s.f.). OpenCV-Python tutorials. [Página web]. https://docs.opencv.org/4.x/d6/d00/tutorial_py_root.html

OpenCV. (s.f.). OpenCV-Python tutorials: Introduction to OpenCV. [Página web]. https://docs.opencv.org/4.x/d6/d00/tutorial_py_root.html

Peguero Núñez, P. (s.f.). Realce y restauración de imágenes. [Documento en PDF]. Universidad de Valladolid. https://www.lpi.tel.uva.es/muitic/pim/docus/Realce_y_restauracion.pdf

Rui, Y., Huang, T. S., & Chang, S.-F. (1999). Image retrieval: Current techniques, promising directions, and open issues. Journal of Visual Communication and Image Representation, 10(1), 39–62. https://doi.org/10.1006/jvci.1999.0413

scikit-image. (s.f.). A crash course on NumPy for images. [Página web]. https://scikit-image.org/docs/stable/user_guide/numpy_images.html

scikit-image. (s.f.). GLCM texture features. [Página web]. https://scikit-image.org/docs/stable/auto_examples/features_detection/plot_glcm.html

scikit-learn. (s.f.). Metrics and scoring: Quantifying the quality of predictions. [Página web]. https://scikit-learn.org/stable/modules/model_evaluation.html

scikit-learn. (s.f.). Recognizing hand-written digits. [Página web]. https://scikit-learn.org/stable/auto_examples/classification/plot_digits_classification.html

Szeliski, R. (2022). Computer vision: Algorithms and applications (2nd ed., caps. 5: Deep learning y 6: Recognition). Springer. https://szeliski.org/Book/

Universidad de Sevilla. (s.f.). Tema 5: Segmentación (regiones, umbralización). [Documento en PDF]. https://asignatura.us.es/imagendigital/Tema5-2_SegmentacionRegionesUmbralizacion.pdf

Universidad Miguel Hernández. (s.f.). Tema 6: Segmentación de la imagen. [Documento en PDF]. https://isa.umh.es/asignaturas/rvc/Tema%206.%20Segmentacion%20de%20la%20imagen.pdf

Varoquaux, G., Gouillart, E., & Vahtras, O. (Eds.). (s.f.). Simple visualization and classification of the digits dataset. Scipy Lecture Notes. [Página web]. https://scipy-lectures.org/packages/scikit-learn/auto_examples/plot_digits_simple_classif.html

11. Referencias complementarias

Canny, J. (1986). A computational approach to edge detection. IEEE Transactions on Pattern Analysis and Machine Intelligence, 8(6), 679–698. https://doi.org/10.1109/TPAMI.1986.4767851

Gonzalez, R. C., & Woods, R. E. (2018). Digital image processing (4th ed.). Pearson. Caps. 1 y 2.

Gonzalez, R. C., & Woods, R. E. (2018). Digital image processing (4th ed.). Pearson. Caps. 3, 4 y 9.

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. En Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (pp. 770–778). https://doi.org/10.1109/CVPR.2016.90

Kapoor, S., & Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. Patterns, 4(9), 100804. https://doi.org/10.1016/j.patter.2023.100804

Kirillov, A., Mintun, E., Ravi, N., Mao, H., Rolland, C., Gustafson, L., Xiao, T., Whitehead, S., Berg, A. C., Lo, W.-Y., Dollár, P., & Girshick, R. (2023). Segment anything. En Proceedings of the IEEE/CVF International Conference on Computer Vision (pp. 4015–4026). https://arxiv.org/abs/2304.02643

Nixon, M. S., & Aguado, A. S. (2019). Feature extraction and image processing for computer vision (4th ed.). Academic Press.

Ojala, T., Pietikäinen, M., & Mäenpää, T. (2002). Multiresolution gray-scale and rotation invariant texture classification with local binary patterns. IEEE Transactions on Pattern Analysis and Machine Intelligence, 24(7), 971–987. https://doi.org/10.1109/TPAMI.2002.1017623

OpenCV. (s.f.). Changing colorspaces. [Página web]. https://docs.opencv.org/4.x/df/d9d/tutorial_py_colorspaces.html

OpenCV. (s.f.). Fourier transform. [Página web]. https://docs.opencv.org/4.x/de/dbc/tutorial_py_fourier_transform.html

OpenCV. (s.f.). Geometric transformations of images. [Página web]. https://docs.opencv.org/4.x/da/d6e/tutorial_py_geometric_transformations.html

OpenCV. (s.f.). Histograms 2: Histogram equalization (incluye CLAHE). [Página web]. https://docs.opencv.org/4.x/d5/daf/tutorial_py_histogram_equalization.html

OpenCV. (s.f.). Morphological transformations. [Página web]. https://docs.opencv.org/4.x/d9/d61/tutorial_py_morphological_ops.html

Otsu, N. (1979). A threshold selection method from gray-level histograms. IEEE Transactions on Systems, Man, and Cybernetics, 9(1), 62–66. https://doi.org/10.1109/TSMC.1979.4310076

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830. https://jmlr.org/papers/v12/pedregosa11a.html

PyTorch. (s.f.). Transfer learning for computer vision tutorial. [Página web]. https://pytorch.org/tutorials/beginner/transfer_learning_tutorial.html

Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional networks for biomedical image segmentation. En Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015 (pp. 234–241). Springer. https://doi.org/10.1007/978-3-319-24574-4_28

scikit-image. (s.f.). Comparison of segmentation and superpixel algorithms. [Página web]. https://scikit-image.org/docs/stable/auto_examples/segmentation/plot_segmentations.html

scikit-image. (s.f.). Histogram of oriented gradients. [Página web]. https://scikit-image.org/docs/stable/auto_examples/features_detection/plot_hog.html

scikit-image. (s.f.). Local binary pattern for texture classification. [Página web]. https://scikit-image.org/docs/stable/auto_examples/features_detection/plot_local_binary_pattern.html

scikit-image. (s.f.). Measure region properties. [Página web]. https://scikit-image.org/docs/stable/auto_examples/segmentation/plot_regionprops.html

scikit-image. (s.f.). Watershed segmentation. [Página web]. https://scikit-image.org/docs/stable/auto_examples/segmentation/plot_watershed.html

scikit-learn. (s.f.). Decomposing signals in components: Principal component analysis (PCA). [Página web]. https://scikit-learn.org/stable/modules/decomposition.html#pca

Stanford University. (s.f.). CS231n: Convolutional neural networks for visual recognition – Convolutional networks. [Notas de curso]. https://cs231n.github.io/convolutional-networks/

Szeliski, R. (2022). Computer vision: Algorithms and applications (2nd ed., cap. 2: Image formation, secc. 2.2–2.3). Springer. https://szeliski.org/Book/

van der Walt, S., Schönberger, J. L., Nunez-Iglesias, J., Boulogne, F., Warner, J. D., Yager, N., Gouillart, E., Yu, T., & the scikit-image contributors. (2014). scikit-image: Image processing in Python. PeerJ, 2, e453. https://doi.org/10.7717/peerj.453

Wang, Z., Bovik, A. C., Sheikh, H. R., & Simoncelli, E. P. (2004). Image quality assessment: From error visibility to structural similarity. IEEE Transactions on Image Processing, 13(4), 600–612. https://doi.org/10.1109/TIP.2003.819861